感官描写与心理描写的自动区分

本报告训练一个逻辑回归分类器，判断一句叙事文本主要属于感官描写还是心理描写。感官描写包括能被五官感知的事物、身体动作或物理状态；心理描写包括人物的想法、情绪、判断、回忆或意图。两者之间的区分看似细微且难以分辨，却构成了叙事分析的基本维度。外部可感的细节与内部心智的活动共同构成人物与世界的关系，把二者操作化为可自动判别的标签，就能批量观察一段文本"向外看"与"向内看"的比例，进而比较不同作者或不同章节的叙事重心。

我们以一句话为单位，标签 0 表示该句主要描写可被五官感知的事物、身体动作或物理状态，也就是感官描写。标签 1 表示主要描写人物的想法、情绪、判断、回忆或意图，也就是心理描写。当一句中两者并重时，以主要谓语和主要描写对象为准。纯对话按引语内容判断，难以判断的话则标为 -1 并排除。数据取自张爱玲《半生缘》正文，以文章中的语句为例，“翠芝一直也没有直接和他说过话，他这一答话，她无故的却把脸飞红了，就没有再说下去”。这句为感官描写，标 0。“但愿他那时候已经有这能力可以养活他母亲、嫂嫂和侄儿，那就不必去跟人家争家产了”。这句为心理描写，标 1。切句后随机抽取 600 句，先用 GLM-5.3-Flash 辅助初标，其中 133 句因属对话或混合句被判为 -1。再人工抽查 50 条，一致率 97.8%，修正 1 条，最终得到 467 条（感官 203、心理 264）。按 80/20 分层划分（随机种子 42）得到训练集 373 条、测试集 94 条。特征采用字符 1–3 gram 的 TF-IDF（5000 维）并配合类别平衡的逻辑回归；之所以用字符而非词级特征，是因为中文没有空格分隔，词级 TF-IDF 会把整句当作一个词元，区分力极弱。

模型在 94 条测试集上取得 0.830 的准确率，混淆矩阵为 [[32, 9], [7, 46]]：41 条感官句中 32 条判对，9 条误判为心理；53 条心理句中 46 条判对、7 条误判为感官。感官类的精确率、召回率、F1 分别为 0.82、0.78、0.80，心理类为 0.84、0.87、0.85，两类表现均衡，说明模型并非偏向多数类。作为对照，我们比较了词频与 TF-IDF 两种字符 n-gram 特征，二者准确率均为 0.830，混淆矩阵仅相差一条，表明在本任务的短句上两种特征区分力相当。值得注意的是，修复前的词级 TF-IDF 模型几乎把所有句子判为心理（准确率 0.60，感官召回仅 0.07），改用字符 n-gram 并加入类别平衡后，感官召回升至 0.78。这说明特征选择而非模型本身才是关键。

在所有的 94 条测试句中有 16 条误分类，错误总体呈现两个模式。第一类是"动作句夹带心理词"，比如"曼璐看了看曼桢的脸色，见她并没有嫌恶的神情"（真实 0，判 1），主谓语本是"看"这一外部动作，但"嫌恶的神情"是心理暗示词，模型被局部词汇主导，忽略了句子整体指向。第二类是"对话句"，例如"曼璐道：'我光明正大的，怕什么？'"（真实 1，判 0），"道"是说话动作、指向感官类，而真正的心理内容"怕"藏在引语里，模型未能给引语更高权重。有趣的是，多数误分类的预测概率集中在 0.50–0.55 之间，说明模型在这些边界句上存在犹豫的现象，而非随机出错。这也表明字符 n-gram 特征学不到句法结构，对话与混合句的地方存在短板。当然，文中的句子不能简单划分为心理描写、感官描写和其他三类，也有个别句子本身处于心理描写和感官描写的边界线上，例如"她忽然发现那孩子浑身冰冷"，"发现"是认知动词，但主体是触觉，人工标注也不清晰，可能有分歧。这类错误反映的是标签定义在混合句上的固有模糊。像是“这大冷天，可别碰见剥猪猡的，一到年底，这种事情特别多”这种带有明显情绪和判断倾向的话，给出的结果都是 1，基本都能判断正确。

为检验模型泛化，我选了一段琼瑶作品作为分析文本，总共 36 句，节选于琼瑶的《聚散两依依》。它不在训练集中，作者风格也与张爱玲明显不同。模型将其中 21 句（58.3%）判为心理描写，但有一点特别的是，多数预测概率集中在 0.48–0.57，与测试集上 0.80 以上的 F1 相比，这段文本的概率几乎全部贴近 0.5，说明模型离开张爱玲语料后区分力明显下降，在陌生文风上高度不确定。例如文中这句，"她拉住他就往花园外跑，嘴里不住地说：'那么，咱们快去吧，还等什么？'"被判为心理（p=0.50）。这句话其实是催促性的对话，模型被"等什么"这类疑问词带偏；而文中的另一句话，"她回过头去，盼云正扶着门框，站在大门口的台阶上，对她静静地注视着。"这句话被判为感官且置信度较高（p=0.31），说明纯动作与视觉描写跨作者仍较稳定。由此可见，模型学到的"心理"信号部分依赖张爱玲的用词习惯（如"觉得""心里""神情"），迁移到情绪更外放、感叹更多的琼瑶文本时判断不稳。因此不应把预测标签直接当作文本的客观属性。它们是训练语料与特征选择共同塑造的结果，跨作者使用时尤其需要谨慎。同时，针对琼瑶的作品，模型出现的错误有一定倾向。感叹句与催促句多被判为心理，例如"还等什么？"这句；而外貌描写多被判为感官，说明模型把"感叹/疑问"当成了心理信号。

本研究在很多方面有所局限。数据方面，467 条来自单一作者、单一作品，规模偏小，结论难以推广到其他文体。标签方面，训练标签由 AI 初标，对话与混合句存在噪声；且初标中有 133 句（占比 22%）无法归入两类，能看出"感官/心理"的二分在边界上本身模糊，部分误差源于定义而非模型。模型方面，字符 n-gram 加逻辑回归只能捕捉局部词片段，学不到句法结构与引号边界，对话句因此成为稳定短板。希望未来我可以找更明显的二分性进行分类，人工标注更多样的文本并尝试更强的序列模型。